Devoir libre

1- Trouver les variables manquantes :

1-a -

+ Le dataset a une taille de : (418,18)
418 lignes et 18 colonnes.

+ Les caractéristiques sont :

- Passengerid
- Pclass
- Name
- Sexe
- Age
- SibSp
- Parch
- Ticket
- Fare
- Cabin
- Embarked

+ La variable cible est :
Survived

+ Pour Données manquantes :
oui, il y en a des valeurs manquantes. car en analysant la fonction info(), on constate que certaines colonnes comme age ont un nombre de valeurs non nulles inférieur au nombre total de lignes.

1-b -

+ L'importance de gérer les données manquantes :
La gestion des données manquantes est essentielle en machine learning pour s'assurer de la qualité des résultats, pour garantir une meilleure prise de décision. Car les valeurs manquantes provoquent :

- réduction de la performance du modèle
- les algorithmes ne fonctionnent pas correctement en présence de données incomplètes
- erreurs d'analyse et des fautes dans les résultats attendus

3- Gérer les variables catégoriques :

3-1 L'encodage choisi est important pour cette variable car les algorithmes de traitement de données et de machine learning ne comprennent pas les données textuelles et ne peuvent pas les interpréter.
Donc il est important de les transformer en valeurs numériques exploitable.

4- Sélection des caractéristiques :

4-a- Les caractéristiques importantes peuvent être identifiées à l'aide de :

- la corrélation
- tests statistiques
- sélection automatique
- Importance des variables
- performance du modèle.

on garde que les variables qui influencent la variable cible

4-b-

4-3-

les valeurs manquantes :
doivent être remplacer soit par la moyenne, la mediane, ou supprimer ces lignes.

les variables categoriques :
Dans le maching learning, ne sont pas comprehensibles. donc ils doivent être encodées. Cette operation s'appelle encodage.

5- Division de l'ensemble de données :

5-3 :

+ Training set : sert à entraîner le modèle et apprendre la relation entre les caractéristiques et la variable cible.

Test set : sert à tester et évaluer la performance du modèle sur d'autres données pas vues.

=> sont important car cette division permet d'éviter le surapprentissage et vérifier si un modèle généralise bien et mesurer la performance

6- Feature Scaling :

StandardScaler : transforme données pour avoir une moyenne égale à 0 et un écart-type égal à 1. les valeurs peuvent être négatives ou positives. Garde la forme de la distribution n

MinMaxScaler : transforme donnée dans l'intervalle [0, 1] c.à.d valeurs entre 0 et 1. garde la forme de distribution mais les valeurs extrêmes peuvent être écrasé. c.àd sensible aux valeurs extrêmes.